به نام خدا

```
import re
import nltk
import pandas as pd

def tokenize(text_array):
    for i in range(len(text_array)):
        if not pd.isna(text_array.loc[i]):
            text_array.loc[i] = text_array.loc[i].replace('\\n',' ')
            text_array.loc[i] = re.sub(r'\https?:\\/\.*[r\n]*', '', text_array.loc[i], flags=re.MULTILINE)
            text_array.loc[i] = re.sub(r'[0-9]*", " ", text_array.loc[i])
            text_array.loc[i] = re.sub(r"[^a-zA-Z0-9]", " ", text_array.loc[i].lower())
            text_array.loc[i] = nltk.word_tokenize(text_array.loc[i])

return text_array

data_csv = pd.read_csv['dataset/train.csv'])

pure_tokens = tokenize(data_csv['Comment'])

pure_tokens_dataframe = pd.DataFrame(pure_tokens)
pure_tokens_dataframe.to_csv('./one_pure_tokens.csv', index=False)

23
```

در این تابع برای ستون کامنت لینک ها ، ۱۸ ها و کلماتی که با یک عدد شروع می شوند را جدا کردیم و سپس جملات را به کلمات توکنایز کردیم.

در این تابع stop word ها را پاکسازی کردیم.

```
import nltk
import pandas as pd

def stemming(text_array):
    for i in range(len(text_array)):
        if not pd.isna(text_array.loc[i]):
            text_array.loc[i] = (text_array.loc[i]).replace("['","", 1).replace("']","", 1).split("', '")
    for i in range(len(text_array)):
        if type(text_array.loc[i]) != float:
            text_array.loc[i] = [nltk.PorterStemmer().stem(w) for w in text_array.loc[i]]
    return text_array

tokens_without_stopwords_csv = pd.read_csv('step2/two_tokens_without_stopwords.csv')

tokens_with_stemming = stemming(tokens_without_stopwords_csv['Comment'])

tokens_with_stemming_dataframe = pd.DataFrame(tokens_with_stemming)
    tokens_with_stemming_dataframe.to_csv('./three_tokens_with_stemming.csv', index=False)

tokens_with_stemming_dataframe.to_csv('./three_tokens_with_stemming.csv', index=False)
```

در این تابع که استفاده نشده است ولی تست و بررسی شده است بر روی دادهها stemming انجام دادهایم ولی با توجه به نتیجه نچندان خوب از lemmetiziation

در این تابع از lemmetizing برای پیدا کردن ریشه کلمات استفاده کردیم.

```
import gensim
def word2Vec(text_array):
    for i in range(len(text_array)):
       if not pd.isna(text_array.loc[i]):
           text_array.loc[i] = (text_array.loc[i]).replace("['","", 1).replace("']","", 1).replace("', '", " ")
   text_array = text_array.apply(gensim.utils.simple_preprocess)
    model = gensim.models.Word2Vec(window=3, min_count=3, workers=4)
   model.build_vocab(text_array, progress_per=10000)
   model.train(text_array, total_examples=model.corpus_count, epochs=70)
   model.save('word2vec.model')
   print(model.wv.get_vector('good'))
    return text_array
tokens_with_lemmatizing_csv = pd.read_csv('step3/three_tokens_with_lemmatizing.csv')
extracted_key_tokens = word2Vec(tokens_with_lemmatizing_csv['Comment'])
extracted_key_tokens_dataframe = pd.DataFrame(extracted_key_tokens)
extracted_key_tokens_dataframe.to_csv('./four_extracted_key_tokens.csv', index=False)
```

در این تابع از word۲vec آموزش داده شده مخصوص دادههای train خودمان برای برداری کردن کلمات و سپس با گرفتن میانگین وزن دار کلمات هر داکیومنت برای برداری کردن داکیومنت ها استفاده کردیم. (این تابع به علت ضعیفتر بودن در برداری کردن داکیومنت ها کنار گذاشته شده و از تابع بعدی برای ادامه الگوریتم استفاده شده است)

```
import pandas as pd
from nltk.tokenize import word_tokenize
def doc2Vec(text_array):
    for i in range(len(text_array)):
        if not pd.isna(text_array.loc[i]):
            text_array.loc[i] = (text_array.loc[i]).replace("['","", 1).replace("']","", 1).replace("', '", "")
    text_array = [gensim.models.doc2vec.TaggedDocument(words=word_tokenize(_d.lower()), tags=[str(i)]) for i, _d in enumerate(text_array)]
    documents_tags_dataframe = pd.DataFrame(text_array)
    documents_tags_dataframe.to_csv('./documents_tags.csv', index=False)
    model = gensim.models.Doc2Vec(dm=1, vector_size=65, hs=1, min_count=2, sample = 12000,window=3, alpha=0.025, min_alpha=0.00025)
    model.build_vocab(text_array)
    model.train(text_array, total_examples=model.corpus_count, epochs=70)
    model.save('doc2vec.model')
    return text_array
tokens_with_lemmatizing_csv = pd.read_csv('step3/three_tokens_with_lemmatizing.csv')
extracted key tokens = doc2Vec(tokens with lemmatizing csv['Comment'])
extracted_key_tokens_dataframe = pd.DataFrame(extracted_key_tokens)
extracted_key_tokens_dataframe.to_csv('./four_point_one_extracted_key_tokens.csv', index=False)
```

در این تابع با توجه به داکیومنت های موجود آنها را با الگوریتم ، Doctvec در این تابع با توجه به داکیومنت های موجود آنها را با الگوریتم و بردار هایی به ازای هر مقاله ساخته شد.

```
def save_function(original_cosine_distance, current_distance, indexes, document_cluster_labels, n_cluster_previous, n_cluster_current):

np.save('./original_cosine_distance', original_cosine_distance)

np.save('./current_distance', current_distance)

np.save('./indexes', indexes)


np.save('./first_current_distance_of_vectors', current_distance)

13
```

در این تابع مقادیر مرحله اول کلاسترینگ به علت زمان بر بودن و حجم زیاد ذخیره شدند تا در مرحله بعد این زمان از زمان اجرای ادامه کلاسترینگ کسر گردد.

```
key_identification_clustering_one(document_vectors, n_clusters)
    original_cosine_distance = np.zeros(shape=(8695, 8695))
    for i in range(len(document_vectors.distances(document_vectors[0]))):
        original_cosine_distance[i] = document_vectors.distances(document_vectors[i])
    original cosine distance = np.where(original cosine distance < 0. 0. original cosine distance)
   nearest_neighbors = NearestNeighbors(n_neighbors=k, metric="precomputed")
   nearest_neighbors.fit(original_cosine_distance)
   distances, indexes = nearest_neighbors.kneighbors()
   document_cluster_labels = [x for x in range(1, len(original_cosine_distance)+1)]
    n_cluster_previous = len(Counter(document_cluster_labels).keys())
    n_cluster_current = math.floor(n_cluster_previous/g)
   current_distance = np.zeros(shape=(n_cluster_previous, n_cluster_previous))
        for j in range(n_cluster_previous):
            current_distance_sigma = 0
                for p in range(k):
                    current_distance_sigma += original_cosine_distance[indexes[i][l]][indexes[j][p]]
        current_distance[i][j] = current_distance_sigma/((k+1)**2)
print("% ", ((i)/(n_cluster_previous))*100)
    print(current distance)
    save_function(original_cosine_distance, current_distance, indexes, document_cluster_labels, n_cluster_previous, n_cluster_current)
    return document vectors
n_cluster_target = 3
model = gensim.models.doc2vec.Doc2Vec.load("step4/doc2vec.model")
key_identification_clustering_one(model.dv, n_cluster_target)
```

در این تابع که قسمت اول کلاسترینگ را محاسبه میکند یعنی این قسمت از فلوچارت را :




با استفاده از تابع فاصله کسینوسی فواصل بین دادهها و کلاستر ها محاسبه شده است.

```
def load_function():
    original_cosine_distance = np.load('step5_1/original_cosine_distance.npy')
    knn_indexes = np.load('step5_1/indexes.npy')
    document_cluster_labels = [x for x in range(len(original_cosine_distance))]
    n_cluster_previous = len(Counter(document_cluster_labels).keys())
    n_cluster_current = math.floor(n_cluster_previous/g)
    current_distance = np.load('step5_1/first_current_distance_of_vectors.npy')
    return original_cosine_distance, current_distance, knn_indexes, document_cluster_labels, n_cluster_previous, n_cluster_current
```

در این تابع متغیر های ذخیره شده در قسمت اول الگوریتم load می شود.

```
def key_item_selection(current_distance_matrix, n_clusters):
   mean_distance_matrix = np.mean(current_distance_matrix, axis=1)
   first_selected_key = np.argmin(mean_distance_matrix)
   selected_keys = []
   selected_keys.append(first_selected_key)
   unselected\_items\_for\_key = [x \ for \ x \ in \ range(0, \ len(current\_distance\_matrix)) \ if \ x \ != first\_selected\_key]
   temp_min_key_j = -1
    temp_max_key_i = -1
   n = len(selected_keys)
   while n < n_clusters:
        temp_max_distance = 0
        for i in unselected_items_for_key:
            temp_min_distance = 10000000000
            for j in selected_keys:
                if current_distance_matrix[i][j] < temp_min_distance:</pre>
                    temp_min_distance = current_distance_matrix[i][j]
                    temp_min_key_j = j
            if current_distance_matrix[i][temp_min_key_j] > temp_max_distance:
                temp_max_distance = current_distance_matrix[i][temp_min_key_j]
        temp_max_key_i = i
selected_keys.append(temp_max_key_i)
        unselected_items_for_key.remove(temp_max_key_i)
   print(len(selected_keys))
   print(selected_keys)
   return selected_keys
```

در این تابع item های کلیدی طبق الگوریتم مقاله انتخاب میشوند برای شناخته شدن به عنوان مرکز کلاسترها



در این تابع که ادامه فایل قبل است این قسمت از فلوچارت در شکل زیر اجرا می شود

```
def key_identification_clustering_two(document_vectors, n_cluster_target):
   original\_cosine\_distance, \ current\_distance, \ knn\_indexes, \ document\_cluster\_labels, \ n\_cluster\_previous
, n_cluster_current = load_function()
   while n_cluster_current > n_cluster_target:
        selected_keys = key_item_selection(current_distance, n_cluster_current)
       # update elements lablels
        for i in range(len(document_cluster_labels)):
           min_distance = MAXINT
           for j in selected_keys:
                if current_distance[document_cluster_labels[i]][j] < min_distance:</pre>
                   min_distance = current_distance[document_cluster_labels[i]][j]
                   new_cluster_label = j
           document_cluster_labels[i] = new_cluster_label
       counter = 0
       cluster_members_with_neighbors = {}
        for i in selected_keys:
           temp = list(locate(document_cluster_labels, lambda a: a == i))
                   temp.append(knn_indexes[1][j])
               temp = list(set(temp))
           cluster_members_with_neighbors[counter] = temp
       current_new_distance = np.zeros(shape=(n_cluster_current, n_cluster_current))
        for i in range(n_cluster_current):
           for j in range(n cluster current):
               current_distance_sigma = 0
                for 1 in cluster_members_with_neighbors[i]:
                    for p in cluster_members_with_neighbors[j]:
                        current_distance_sigma += original_cosine_distance[l][p]
                current_new_distance[i][j] = current_distance_sigma/(len(cluster_members_with_neighbors[
i])*len(cluster_members_with_neighbors[j]))
           print("update current distance matrix %", ((i)/(n_cluster_current))*100)
       n_cluster_previous = n_cluster_current
       n_cluster_current = math.floor(n_cluster_current/g)
       current_distance = current_new_distance
       cluster_label_dict_current = {}
        for i in selected_keys:
           cluster_label_dict_current[i] = c
            c += 1
        for i in range(len(document_cluster_labels)):
            document_cluster_labels[i] = cluster_label_dict_current[document_cluster_labels[i]]
    selected_keys = key_item_selection(current_distance, n_cluster_target)
    for i in range(len(document_cluster_labels)):
       min_distance = MAXINT
            if current_distance[document_cluster_labels[i]][j] < min_distance:</pre>
               min_distance = current_distance[document_cluster_labels[i]][j]
                new_cluster_label = j
       document_cluster_labels[i] = new_cluster_label
   cluster_label_dict_current = {}
    for i in selected_keys:
       cluster_label_dict_current[i] = c
    for i in range(len(document_cluster_labels)):
       document_cluster_labels[i] = cluster_label_dict_current[document_cluster_labels[i]]
    return document_cluster_labels
```

در این تابع که طبق فلوچارت و توضیحات مقاله نوشته شده است الگوریتم مقاله اجرا می شود و در نهایت لیبل های پیش بینی شده برای دادههای train مشخص می گردد.

در کد صفحهی بعد دستورات مربوط به اجرای الگوریتم و گرفتن اطلاعاتی راجع به صحت و درصد درستی نتایج داده شده نوشته شده است و همچنین بازنمایی داکیومنت ها در اسکتر پلات برای درک بیشتر نمایش داده شده است. و همچنین این الگوریتم همراه با الگوریتم خوشه بندی k-means اجرا شده تا تفاوت دقت این دو الگوریتم بررسی شود.

```
g = 40
n_cluster_target = 3
 model = gensim.models.doc2vec.Doc2Vec.load("step4/doc2vec.model")
 labels = pd.read_csv('dataset/train.csv')
 key_identification_clusters = key_identification_clusterinq_two(model.dv, n_cluster_tarqet)
 kmeans = KMeans(n clusters=n cluster target)
li = np.zeros(shape=(8695, 65))
x = np.zeros(shape=(8695, 1))
y = np.zeros(shape=(8695, 1))
for i in range(len(model.dv)):
    li[i] = np.array(model.dv[i])
    x[i] = li[i][0]
    y[i] = li[i][1]
# Our labels
for i in range(len(key_identification_clusters)):
    print(key_identification_clusters[i], labels["Topic"].iloc[i])
Biology_0 = 0
Biology_1 = 0
Chemistry_0 = 0
Chemistry_1 = 0
 Physics_1 = 0
 for i in range(len(key_identification_clusters)):
    if key_identification_clusters[i] == 0:
                if labels["Topic"].iloc[i] == "Biology":
    Biology_0 += 1
if labels["Topic"].iloc[i] == "Chemistry":
    Chemistry_0 += 1
                 if labels["Topic"].iloc[i] == "Physics":
    Physics_0 += 1
                 Biology_1 += 1
if labels("Topic"].iloc[i] == "Chemistry":
Chemistry_1 += 1
if labels("Topic"].iloc[i] == "Physics":
Physics_1 += 1
                 Biology_2 += 1
if labels["Topic"].iloc[i] == "Chemistry":
                 Chemistry_2 += 1
if labels["Topic"].iloc[i] == "Physics":
    Physics_2 += 1
#key_identification_cluster colors
key_identification_cluster_colors = np.asarray(key_identification_clusters)
        fir lange(len(labels) Topic []);
fi labels("Topic"].iloc(i] == "Biology":
    main_colors(i] = 0
if labels("Topic"].iloc(i] == "Chemistry":
    main_colors(i] = 1
if labels("Topic").iloc(i] == "Physics":
    main_colors(i] = 2
print("Kmeans Accuracy:", (100*metrics.accuracy_score(main_colors, kmeans_colors)))
print("Key Identification Accuracy:", (100*metrics.accuracy_score(main_colors,
key_identification_cluster_colors)))
print("Biology_0", Biology_0)
print("Biology_1", Biology_1)
print("Biology_2", Biology_2)
print("Chemistry_0", Chemistry_0)
print("Chemistry_1", Chemistry_1)
print("Chemistry_1", Chemistry_1)
print("Chemistry_2", Chemistry_2)
print("Chemistry_2", Chemistry_2)
print("Physics_0", Physics_0)
print("Physics_1", Physics_1)
print("Physics_2", Physics_2)
 plt.scatter(x, y, c=kmeans_colors)
 plt.show()
```